

Sistema adaptativo de decisión ante fraude transaccional

Curso Planificación y Toma de Decisiones en IA, UTEC **Dataset** IEEE-CIS Fraud Detection, partición `train`, 590 540 transacciones en 182 días
Semilla 42. Retraso de etiqueta $L = 30$ días. **Cadencia** 15 días

Resultado principal. IEEE-CIS presenta concept drift sin presentar data drift. La distribución de entrada se mantiene estable, con un AUC de 0,551 en el domain classifier, mientras que la relación entre features y fraude sí cambia: a volumen constante de 46 días, retroceder el corte 30 días encarece 0,1059 UM/tx, y es la única comparación controlada que resiste 18 combinaciones de semilla y bloque. Esa magnitud queda por debajo de lo que cuesta entrenar con menos muestra, de modo que la estrategia expansiva resulta la más barata de las siete y ninguna ventana deslizante se distingue del modelo estático de forma estable.

Página 1. El problema de decisión

Por qué la predicción no agota el problema

El sistema decide, para cada transacción, entre aprobar, enviar a revisión o bloquear. Cuatro restricciones definen qué significa un buen modelo en este contexto.

1. La etiqueta confirmada llega 30 días después del evento. Ninguna métrica de error está disponible en el momento de decidir.
2. La capacidad humana de revisión es de 150 casos diarios. Constituye un techo, no un parámetro a optimizar.
3. Un falso negativo cuesta el monto de la transacción. Un falso positivo cuesta fricción con un cliente legítimo.
4. La distribución de los datos cambia con el tiempo.

Objetivos y verificación

Obj.	Enunciado	Criterio	Resultado obtenido
O1	Menor costo que la política actual y que el modelo estático	Inferior a 5,40 y a 2,09 UM/tx	Cumplido por la estrategia recomendada, con 1,98 UM/tx. La ventaja sobre el estático no es concluyente bajo el control de robustez
O2	Limitar la caída de PR-AUC	Caída superior al 10 % genera alerta	El AP de S0 pasa de 0,526 a 0,514 entre bloques extremos
O3	Respetar la capacidad de revisión	150 casos diarios como máximo	Cumplido sin excepción en 62 días
O4	Señales sin etiqueta que anticipen la caída	Medir el retraso de cada señal	KS/PSI y S1 el mismo día. ADWIN a 30 días
O5	Limitar la disparidad entre segmentos	Brecha superior a 2 pp genera alerta	2 de 14 segmentos con soporte superan el umbral

Familias de métricas

Las métricas técnicas comprenden Average Precision, skill normalizado por prevalencia, F1 y balanced accuracy en un umbral declarado, recall a FPR máximo del 1 %, recall a precisión mínima del 80 %, Brier, ECE y latencia p50, p95 y p99.

Las métricas de decisión comprenden costo observado simulado por transacción, monto de fraude evitado, costo de falsos positivos, retorno por analista hora, revisiones diarias y demanda excedente.

Las métricas sociales comprenden el bloqueo de clientes legítimos, distinto del FPR del clasificador porque incorpora las legítimas que el analista bloquea por error, la disparidad por segmento con soporte e intervalos, y la cobertura automática.

El sistema distingue el cambio en $P(X)$ del cambio en $P(y|X)$. KS/PSI y el domain classifier detectan el primero. Solo ADWIN sobre el error real observa el segundo, con 30 días de retraso.




Figura 1. Comparación de las siete estrategias sobre los mismos eventos. El diagrama de los cinco componentes está en `docs/arquitectura.mmd`.

Componentes

La adquisición integra dos fuentes por left join uno a uno sobre TransactionID, validado por invariancia del número de filas. Ambas son tabulares, de modo que el sistema realiza integración multi-fuente y no multimodalidad en sentido estricto. El diagrama identifica los adaptadores donde entrarían texto de producto e historial de sesión, declarados como extensión y no como implementación. El predictor compara regresión logística, Random Forest y LightGBM, con el preprocessing ajustado dentro de cada fit. La decisión aplica el costo esperado sujeto al cupo de revisión. La incertidumbre se trata con calibración de Platt por versión e intervalos por bootstrap de bloques.

Cálculo de la decisión

Para probabilidad calibrada p y monto m ,

$$\begin{aligned} E[\text{aprobar}] &= p * m \\ E[\text{bloquear}] &= (1 - p) * c_{FP} \\ E[\text{revisar}] &= c_R + p * (1 - r_H) * m + (1 - p) * f_H * c_{FP} \end{aligned}$$

con $c_R = 1$ UM, $r_H = 0,90$ y $f_H = 0,02$. La unidad monetaria es consistente con TransactionAmt y no se convierte a moneda.

Se revisa si $\min(E[\text{aprobar}], E[\text{bloquear}]) - E[\text{revisar}] > \lambda$, y en otro caso la transacción recibe la más barata entre aprobar y bloquear. No hay umbrales sobre p que decidan: el punto de indiferencia entre aprobar y bloquear es $p^* = c_{FP} / (m + c_{FP})$, de modo que depende del monto y un corte fijo bloquea de más en los montos bajos y de menos en los altos. Sobre la reserva de desarrollo la regla de dos umbrales cuesta 1,9696 UM/tx frente a 1,5895 de la económica, y eso que los umbrales se eligen minimizando sobre esa misma ventana.

Con montos bajos el costo fijo c_R supera la pérdida esperada, de modo que la revisión deja de ser la acción de menor costo. Esa es la razón de que el sistema tenga una tercera acción y no una decisión binaria.

Los dos parámetros de la política se derivan de una cantidad observable en lugar de fijarse por criterio. El costo de un falso positivo no es observable, pero la fracción de transacciones legítimas rechazadas sí lo es y es lo que la operación restringe, de modo que se declara el objetivo del 1 % y se busca el menor c_{FP} que lo cumple, que resulta 25 UM y alcanza un 0,89 %. El parámetro λ es el multiplicador de Lagrange del cupo y raciona una plaza escasa. Se calibra por bisección como el menor valor que ajusta la demanda diaria a las 150 plazas, la deja en 150 exactas y resulta 7,86 UM.

Ninguna de las dos calibraciones mira el costo observado. c_{FP} se ajusta contra una tasa declarada y λ contra la capacidad, de modo que la política no se ajusta al desenlace de la ventana. Se condicionan mutuamente y se calibran alternando hasta estabilizarse, lo que ocurre en tres pasadas. Ambos quedan sellados en el prerregistro.

Evidencia sobre la necesidad de calibrar

La aritmética anterior exige que p sea una probabilidad y no un puntaje ordenado. La configuración ganadora de la regresión logística usa `class_weight=balanced`, que infla los puntajes hasta un ECE de 0,28501; Platt lo corrige a 0,00440, una mejora por un factor de 65. Sin esa corrección, usar el puntaje crudo como probabilidad produciría un exceso de bloqueos que el AP no reflejaría. La tabla completa por familia está en `reports/tables/comparacion_modelos.csv`.

Cola, cupo y supervisión humana

El cupo se reserva al admitir, de forma irrevocable y por `event_id`. El sistema no ordena el día completo por $p \times \text{monto}$ para retener los 150 mejores casos, porque eso exigiría conocer transacciones que aún no ocurrieron. La prioridad ordena el servicio entre los ya admitidos y, agotado el cupo, el caso recibe la más barata entre aprobar y bloquear.

Ninguna alerta despliega por sí sola. El reentrenamiento y la promoción exigen autorización humana registrada aunque todos los gates técnicos pasen. Sin versión válida el servicio responde 503 y pausa.




Figura 2. Prevalencia semanal con intervalo de Wilson, volumen, faltantes por familia de columnas y cobertura de identidad.

Integración auditada

Comprobación	Resultado
Transacciones	590 540 filas, 394 columnas
Identidad	144 233 filas, 41 columnas
Filas tras el join	590 540, invariante
Cobertura de identidad	24,42 %
Identificadores de identidad huérfanos	0
Prevalencia global	3,50 %, 20 663 fraudes
Monto mediano	68,77

La ausencia de identidad constituye información y se preserva en `has_identity`. Eliminar esas filas sesgaría el panel hacia clientes con dispositivo identificado.

Relojes derivados

`TransactionDT` es un delta en segundos desde un origen desconocido, no una fecha. De él se derivan `dia`, `semana` y una `hora` relativa que funciona como ciclo de 24 horas y no identifica hora local ni día laboral.

El reloj de evento determina qué features son visibles. El reloj de disponibilidad, definido como `available_at = dia + 30`, determina cuándo una etiqueta puede entrar a un fit, a una métrica o a ADWIN.

Features causales y calidad de los proxies

El sistema construye tres proxies de entidad y, para cada uno, conteos y montos en ventanas de 1 hora, 24 horas y 7 días, rezago del monto, tiempo desde el último evento y conteo expansivo.

Proxy	Definición	Entidades	Eventos por entidad	Singletons
Emisor	card1 a card6 más addr1	43 018	13,7	40,4 %
Cliente	card1 + addr1 + D1n	217 850	2,7	57,5 %
Dispositivo	DeviceType + DeviceInfo	1 943	74,2	26,0 %

Las dos claves de tarjeta se usan a la vez. `D1` mide los días desde que la tarjeta empezó a usarse, de modo que restarlo del día absoluto identifica la fecha de alta y separa tarjetas distintas del mismo emisor. Entrenando LightGBM solo con features de historial sobre un test temporal, cada clave por separado alcanza AP de 0,1668 y 0,1671, y juntas 0,1829: la gruesa aporta soporte estadístico y la fina resolución por tarjeta. Un proxy agrupa comportamiento y no identifica personas.

Los conteos expansivos quedan fuera del predictor porque acumulan desde el primer evento, de modo que crecen con el calendario y sustituyen al día absoluto, que el protocolo prohíbe. La media de `card_cnt_expansivo` pasa de 138,78 en `[0,60]` a 707,43 en `[150,182]`, mientras `card_cnt_7d` no correlaciona con el día. Una validación adversarial por feature lo confirma: de las 425 columnas del panel solo dos superan el AUC de 0,70 que la competencia usaba para descartar, y ambas son conteos expansivos.


Controles de leakage

Las 145 pruebas de `tests/` verifican los controles. Cuatro resultan decisivas. Alterar las filas futuras no modifica medianas ni vocabulario del preprocessing. Invertir las etiquetas aún inmaduras no cambia el predictor. Permutar los identificadores de eventos con el mismo timestamp deja las features idénticas. Los cuatro roles de cada versión no comparten ningún `TransactionID`.

Página 4. Protocolo temporal

Particiones

Todos los intervalos son semiabiertos y se expresan en días relativos.



En cada actualización T de $\{120, 135, 150, 165\}$, con $c = T - 30$, los roles se distribuyen de la forma siguiente.

Rol	Intervalo	Días efectivos
Predictor	$[c - W, c - 14)$	16 con W30, 46 con W60, 76 con W90
Calibrador	$[c - 14, c - 7)$	7
Validación de promoción	$[c - 7, c)$	7

Hay dos reservas por versión, no tres. Los umbrales de referencia se eligen una sola vez en desarrollo y quedan congelados, de modo que reservar una ventana de política en cada actualización excluía siete días del fit sin cumplir función. Liberarla beneficia sobre todo a las ventanas cortas, que son las que el experimento evalúa: W30 pasa de 9 a 16 días de fit.

Las dos reservas son idénticas para todas las estrategias. Esa igualdad permite atribuir una diferencia de costo al tamaño de ventana.

El experimento separa volumen de frescura por diseño. Variar solo W cambiaba a la vez cuántos días entrena el modelo y cuán reciente es su información, de modo que ninguna diferencia era atribuible. El diseño vigente añade un bloque de antigüedad variable con volumen constante.

Bloque	Estrategias	Qué varía	Qué se mantiene
Volumen variable	W30, W60, W90	días de fit	corte en $c - 14$
Antigüedad variable	W60, R46_medio, R46_antiguo	punto de corte	46 días de fit

Distinción entre cutoff y tiempo del job

$cutoff = T - L$ delimita qué días de evento pueden usarse. $job_time = T$ indica cuándo se ejecuta el ajuste y constituye el valor contra el que se compara $available_at$. Con T igual a 120 y L igual a 30, el último día de evento con etiqueta confirmada es el 89. Comparar contra $cutoff$ en lugar de job_time exigiría $día < 60$ y dejaría vacías las colas de calibración y validación.

Orden de construcción

El orden es predictor, calibrador y validación. Cada paso consume scores producidos por el anterior sobre datos que ese paso no vio. Invertir el orden haría que el calibrador corrigiera un modelo distinto del que se despliega. La política no consume una reserva propia, porque se congela en desarrollo y consiste en el modelo de costos.

Si un rol no alcanza el soporte mínimo de 200 fraudes y 2 000 legítimas en el fit, la versión se marca no válida. El sistema no amplía la ventana ni incorpora etiquetas inmaduras para completar el soporte.

Prerregistro

La familia, los hiperparámetros, la economía calibrada y la ventana desplegable se congelan usando solo desarrollo. El hash `7d4c9fac0af4d15f` sella esa selección antes de abrir el test. `c_FP` entra al sello porque pasó de ser una constante del config a un parámetro derivado de los datos de desarrollo, de modo que sin sellarlo sería posible recalibrarlo después de ver el test. Si la configuración cambiara entre la selección y el test, la corrida se detiene.

El benchmark histórico que seleccionó IEEE-CIS ya examinó periodos tardíos del dataset. Este trabajo continúa siendo un backtest retrospectivo y no una validación prospectiva.




Figura 3. Evolución de AP, costo y Brier del sistema estático en el periodo de test, con la tasa base superpuesta.

Comparación de familias

La selección aplica el criterio de costo, no el de AP. El proceso ejecuta 18 fits de tuning y tres ajustes finales.

Familia	Config	AP	Costo UM/tx con la regla económica	Costo con el mejor umbral fijo
LightGBM	lgbm_31	0,6214	1,5895	1,9696
Random Forest	r_f_200_20	0,5391	1,8728	2,2746
Logística	lr_c1_bal	0,4029	2,1910	2,8712

Las referencias simuladas sobre la reserva de política alcanzan 4,5937 UM/tx al aprobar todo y 24,1365 UM/tx al bloquear todo. LightGBM queda congelada como familia adaptativa.

La columna de umbral fijo es el costo que alcanzaría el mejor par de cortes globales sobre p , elegido por minimización sobre la misma reserva. La diferencia con la columna de argmin mide lo que cuesta ignorar el monto.

La regla económica induce un umbral distinto por monto. Con la economía calibrada:

Monto	Revisar desde	Bloquear desde
25,00 UM	$p \geq 0,4072$	$p \geq 0,5791$
59,00 UM	$p \geq 0,1747$	$p \geq 0,5143$
250,00 UM	$p \geq 0,0415$	$p \geq 0,3159$

Objetivos diagnósticos y AP por bloque

El AP del sistema estático pasa de 0,5257 en B1 a 0,5144 en B4, sin degradación monótona. El descenso común en B2, hasta 0,3907, afecta a las siete por igual, incluidas las que se reentrenan, de modo que corresponde a un periodo más difícil y no a un modelo que caduca.

Los umbrales diagnósticos se eligieron en validación y se aplicaron congelados. Ninguna estrategia alcanza el FPR máximo del 1 % ni la precisión mínima del 80 % en test. El FPR obtenido queda entre 0,78 % y 1,18 % y la precisión entre 75,4 % y 82,5 %. El informe reporta el nivel obtenido y no ajusta el umbral, porque hacerlo convertiría un objetivo incumplido en un resultado ajustado a posteriori.

Selección de la ventana y estrategia recomendada

El protocolo exige elegir la ventana con datos de desarrollo. La evaluación se realiza sobre la reserva de validación, posterior al predictor y al calibrador de cada paquete.

Estrategia	Días de fit	Fraudes en el fit	Costo UM/tx en desarrollo
W60	46	5 768	2,2527
W90	76	9 169	2,2708
W30	16	2 191	2,3501

W60 y W90 quedan separadas por un 0,80 %, dentro del margen de desempate del 1 % que favorece la ventana menor. W30 queda un 4,33 % por encima. W60 es por tanto la ventana deslizante elegida, y la elección se hizo sin observar el test.

El enunciado §3.5 lista el reentrenamiento periódico junto a las ventanas deslizantes entre las estrategias de adaptación admisibles. Sobre el test, la estrategia expansiva, que reentrena cada 15 días sobre todo el histórico, alcanza 1,9840 UM/tx frente a 2,0921 del modelo estático y 2,1087 de la ventana elegida, de modo que es la que el informe recomienda operar. Su ventaja sobre el estático, del 5,2 %, no alcanza el criterio de robustez, y esa salvedad acompaña la recomendación.

Página 6. Resultado del experimento central

Siete estrategias evaluadas sobre los mismos eventos, la misma semilla, la misma política y la misma familia. 175 998 eventos por estrategia en cuatro bloques. Las tres primeras varían el volumen de entrenamiento y las tres últimas lo mantienen constante en 46 días variando solo la antigüedad.

Estrategia	Días de fit	AP	Brier	Costo UM/tx con IC 95 %	Δ frente a S0	Bloqueo legítimas	Versiones
E15 (recomendada)	76 a 121	0,4965	0,0231	1,9840 [1,821 y 2,155]	−0,108 [−0,205 y 0,002]	1,26 %	4
W90	76	0,4901	0,0234	2,0573 [1,909 y 2,208]	−0,035 [−0,128 y 0,061]	1,36 %	4
S0 (ref.)	69	0,4828	0,0233	2,0921 [1,911 y 2,256]	referencia	0,87 %	1
W60	46	0,4802	0,0237	2,1087 [1,917 y 2,330]	0,017 [−0,114 y 0,165]	1,38 %	4
R46_antiguo (diag.)	46	0,4681	0,0236	2,1171 [1,943 y 2,246]	0,025 [−0,059 y 0,090]	0,98 %	1
W30	16	0,4701	0,0238	2,1830 [1,943 y 2,421]	0,091 [−0,061 y 0,280]	1,27 %	4
R46_medio (diag.)	46	0,4571	0,0242	2,2146 [2,033 y 2,382]	0,123 [0,004 y 0,229]	1,40 %	4

Intervalos por bootstrap pareado de bloques contiguos de 7 días con 200 remuestreos.

Volumen frente a frescura

Un intervalo obtenido con una semilla fija puede excluir el cero por azar. Toda diferencia se reevalúa con 6 semillas y 3 tamaños de bloque, 18 combinaciones, y solo se declara concluyente si ninguna cruza el cero. Con ese criterio, Ninguna de las 6 diferencias frente a S0 resiste el control. Todas cruzan el cero en al menos una de las 18 combinaciones, de modo que el informe no declara concluyente ninguna comparación contra el modelo estático.

El experimento separa volumen y frescura por diseño. El bloque de volumen variable mueve los días de fit manteniendo el corte, y el de antigüedad variable mueve el corte manteniendo 46 días de fit.

Comparación	Qué aísla	Efecto	Cruzan cero	Veredicto
R46_antiguo frente a W60	Frescura, corte al inicio del histórico	0,0084	18 de 18	no concluyente
W60 frente a W90	Volumen, 46 frente a 76 días	0,0514	18 de 18	no concluyente
W30 frente a W60	Volumen, 16 frente a 46 días	0,0742	4 de 18	no concluyente
R46_medio frente a W60	Frescura, corte 30 días más antiguo	0,1059	0 de 18	concluyente
W30 frente a W90	Volumen, 16 frente a 76 días	0,1257	1 de 18	no concluyente

Solo 1 de las 5 comparaciones resiste el control de robustez, y es la de frescura: con el volumen fijo en 46 días, retroceder el corte 30 días encarece 0,1059 UM/tx con las 18 combinaciones excluyendo el cero. Variar el volumen entre 16 y 76 días con el mismo corte da 0,1257, de magnitud parecida pero menos estable. El efecto de la antigüedad no es monótono: tomar los 46 primeros días del histórico no se distingue de la ventana más fresca, con 0,0084. La correlación entre días de fit y costo es de −0,7412.

El dataset presenta concept drift sin presentar data drift, y la evidencia separa ambas afirmaciones. La distribución de entrada se mantiene estable, con un AUC de 0,551 en el domain classifier frente a un umbral de alerta de 0,75 y ninguna columna original por encima de 0,61 en la validación adversarial por feature. La relación entre features y fraude sí cambia, y lo registran las 49 detecciones de ADWIN sobre el error individual. El efecto de frescura medido a volumen constante solo puede provenir de ese cambio, dado que las entradas permanecen estables.

La magnitud de ese drift, 0,1059 UM/tx por cada 30 días de antigüedad, queda por debajo de lo que cuesta entrenar con menos muestra. Esa es la razón de que descartar histórico no resulte rentable en este dataset.

Contraste con la literatura sobre el mismo dataset

Topal et al. [1] comparan sobre IEEE-CIS modelos congelados tras los primeros 16 días contra modelos reentrenados a diario, y concluyen que existe concept drift. Su titular, un recall a FPR del 5 % de 0,03 frente a 0,37, parece contradecir lo anterior. Su tabla por familia no lo hace.

Familia	Congelado	Reentrenado	Caída
XGBoost	0,04	0,35	−89 %
LightGBM	0,03	0,37	−92 %
Random Forest	0,25	0,33	−24 %
Logística	0,29	0,30	−3 %
Este trabajo, LightGBM congelado 136 días	0,3769	0,4240	−11 %

El colapso se concentra en los dos boosters, cuyo recall de 0,03 y 0,04 a FPR del 5 % queda por debajo del 0,05 que produciría una asignación aleatoria. Una deriva del fenómeno degradaría a las cuatro familias en proporción parecida, y Random Forest y la logística caen un 24 % y un 3 %, que es el orden de magnitud medido aquí.

La medición de aquí es directa. La estrategia congelada en los días 0 a 46 y usada hasta el 182 conserva su AP, con 0,5077 en B1 y 0,5103 en B4, de modo que 136 días de antigüedad no la degradan bajo este panel de features.

El diseño de aquí permite además una distinción que el suyo no necesita hacer, entre reentrenar y descartar histórico. Su método de reentrenamiento usa todos los datos disponibles, y en este trabajo la estrategia expansiva, que reentrena cada 15 días sin descartar, resulta la más barata de las siete.

Página 7. Despliegue, operación y costo

Entregado frente a diseñado

Entregado y verificado localmente	Ejecuta el equipo de forma manual
Paquete versionado con hashes	Publicación de la imagen en Artifact Registry
Imagen Docker construida y probada	Creación del servicio en Cloud Run
Servicio HTTP con /health y /predict	Apuntar el replay al endpoint remoto
Replay con ledger SQLite transaccional	Promoción, rollback y cierre de recursos
Runbook y política de promoción	

Pub/Sub, Firestore, BigQuery, Cloud Scheduler y Vertex AI Pipelines figuran en el diagrama como diseño futuro. No existen recursos creados ni código de integración.

Evidencia de la demo local

Comprobación	Resultado
Tres acciones sobre datos reales	4 678 aprobar, 201 revisar, 121 bloquear
Cupo respetado	Nunca excedido en 62 días
Idempotencia con 50 reenvíos	Aprobada, sin consumo adicional de cupo
Imagen Docker	linux/amd64 , 1,06 GB, HEALTHCHECK en verde
Paridad contenedor frente a cálculo offline	Probabilidad, costos y acción emitida
Latencia p95 sobre HTTP al contenedor	90,1 ms frente a un objetivo de 300 ms
Acciones del contenedor sobre 1 000 peticiones	951 aprobar, 38 revisar, 11 bloquear
Sin paquete montado	/health informa model_unavailable y /predict devuelve 503
Cambio de versión y rollback	Score restaurado de forma exacta

Señales de drift y gates

ADWIN registra 49 detecciones entre las 7 estrategias, todas con 30 días de retraso: existe deriva en el error real. Las señales sin etiqueta generan 2 alertas sobre 497 registros y el domain classifier no se acerca a su umbral. El error deriva mientras las covariables se mantienen estables.

Ningún gate bloqueó una promoción: las 22 evaluaciones recomendaron activar o promover. El gate social no tiene nada que bloquear porque la brecha máxima entre segmentos es de 0,70 puntos frente a un umbral de 2, consecuencia de calibrar c_FP contra el objetivo de bloqueo de legítimas. Los gates quedan como control activo, no como trámite: runs/v3/gates.csv registra cada evaluación con su motivo.

Frecuencia, autonomía y gates

El reentrenamiento ocurre cada 15 días con la ventana W60 elegida en desarrollo. El monitoreo aplica KS/PSI a diario, S1 por bloque y ADWIN al madurar cada etiqueta. Cinco gates controlan la promoción. El primero verifica integridad y bloquea la versión ante cualquier leakage. El segundo exige costo inferior al de aprobar todo en el arranque. El tercero aplica no inferioridad con costo máximo de 1,01 veces el del champion, caída de AP no superior a 0,01 y aumento de Brier no superior a 0,005. El cuarto limita el aumento del bloqueo de legítimas a 2 puntos porcentuales. El quinto exige autorización humana registrada.

El rollback técnico responde a errores HTTP superiores al 1 % o a p95 por encima de 300 ms en dos lotes consecutivos, y opera de forma inmediata bajo regla preautorizada. El deterioro de negocio solo puede afirmarse con etiquetas maduras, 30 días después, y exige revisión humana.

Costo de cómputo

Trabajo	Tareas	Minutos
Tuning	18	17,3
Ajustes finales y de adaptación	6	9,9
Selección de ventana	3	0,8
Backtest completo	1	3,2
Datos y features	5	0,3
Total	33	31,5 de 480

El perfil completo de recursos cupo dentro del presupuesto declarado.

Escala, costo e integración

El informe no estima montos porque dependen de la cuenta, la región y el tráfico. Los factores de costo son el consumo de CPU y memoria por petición junto con el cold start en serving, el tamaño de la ventana y el ancho del panel en reentrenamiento, y el número de versiones retenidas junto con el volumen de logs en almacenamiento.

Tres límites quedan declarados. El cupo está garantizado únicamente para un orquestador secuencial. La latencia medida es local y no representa una región cloud. El prototipo asume identidad simultánea y features precomputadas.

Página 8. Límites y conclusión

Afirmaciones que no se sostienen

Afirmación	Motivo
El olvido mejora el costo	No ocurre. Ninguna ventana deslizante bate al estático
Existe concept drift demostrado	ADWIN detecta deriva en el error. La comparación temporal no la identifica causalmente
La ventana elegida es la óptima	Es la mejor de tres, con una cadencia y una semilla
El sistema es justo	La disparidad medida es operativa, sin atributos protegidos verificables
El sistema funciona en producción	El cupo está garantizado solo para un orquestador secuencial
Existe un ahorro económico medido	Los costos son simulados y <code>c_FP</code> es el precio sombra de un objetivo declarado

Alcance, selective labels y riesgos residuales

El resultado no invalida el diseño adaptativo. Indica que la cadencia de 15 días con `L` igual a 30 no encuentra deriva suficiente para justificar el descarte de datos, y el protocolo no puede evaluar adaptación más rápida que `L`, porque con un retraso de etiqueta de 30 días toda versión nace con esa antigüedad. `W30` entrena con 2 191 fraudes frente a los 9 169 de `W90`. El proxy de emisor presenta un 40 % de singletons y el de cliente un 57 %, de modo que las features de historial aportan menos de lo que aportarían con entidades recurrentes.

El núcleo emplea información completa, de modo que toda etiqueta madura a los 30 días incluso si la acción simulada fue bloquear. En operación real una transacción bloqueada no revela su desenlace y las etiquetas quedarían sesgadas por las decisiones previas del sistema. La corrección mediante masked label quedó fuera del alcance.

El precio sombra del cupo administra mejor la escasez, pero no la elimina. Con 150 plazas diarias el sistema resuelve de forma automática la gran mayoría de las transacciones, de modo que mejorar el AP presenta rendimientos decrecientes.

Los riesgos residuales cuentan con controles entregados. Platt por versión corrige los scores descalibrados, la cadencia y el cooldown de 15 días limitan la oscilación de versiones, `available_at` gobierna las etiquetas tardías, la ausencia de modelo válido produce 503 y pausa, y el hash de preregistro bloquea el retuning tras observar el test.

Conclusión

El sistema reduce el costo observado de 5,40 a 1,98 UM por transacción frente a aprobar todo, una mejora del 63,2 %. Esa reducción proviene del modelo y de la política económica; la adaptación por ventanas no contribuye a ella.

La estrategia más barata es `E15`, que reentrena sobre todo el histórico, y la más cara es `R46_medio`. Ninguna de las 6 diferencias frente al modelo estático resiste el control de robustez.

Las comparaciones controladas sí encuentran señal. Retroceder el corte 30 días con el volumen fijo en 46 encarece 0,1059 UM/tx, única comparación que resiste las 18 combinaciones de semilla y bloque. El efecto del volumen, 0,1257 entre 16 y 76 días, es de magnitud parecida pero no alcanza ese criterio. Ambos factores importan poco: el rango completo de las siete estrategias va de 1,98 a 2,21 UM/tx, un 11,6 %.

La recomendación operativa es el reentrenamiento periódico sobre todo el histórico cada 15 días, con monitoreo activo. `W60` fue la ventana deslizante elegida en desarrollo, y ninguna de las tres aporta valor sobre esa alternativa. Una revisión posterior debería evaluar cadencias y retrasos menores que los 30 días de `L`, que es el régimen que este protocolo no alcanza.

Este trabajo constituye un backtest retrospectivo. Un backtest no demuestra que el sistema funcione en el futuro.

Trazabilidad

Cada cifra es trazable a un `run_id` y a un artefacto con hash en `reports/indice_evidencia.csv`.

[1] Topal, Bozanta, Erer y Başar,

Handling Concept Drift in Fraud Detection: A Replication Study

, 38th Canadian Conference on Artificial Intelligence, Calgary, 2025.

Los antecedentes son `propuesta_proyecto1_final.md`, `concept_drift_findings.md` y `concept_drift_benchmark_instructions.md`. El benchmark que seleccionó IEEE-CIS se cita como evidencia consistente con drift, no como prueba causal, y sus limitaciones de preprocessing quedan declaradas.

Las decisiones de diseño y la medición que sustenta cada una están en `docs/decisiones_de_diseno.md`.

El protocolo está en `docs/protocolo_experimental.md`, el contrato en `docs/contrato_sistema.md` y la reproducción en `docs/reproducibilidad.md`. El despliegue está en `deploy/gcp_runbook.md` y `deploy/promocion_rollback.md`. La evidencia ejecutable consta de tres notebooks en `notebooks/` y 145 pruebas en `tests/`.