

Sistema adaptativo de decisión ante fraude transaccional

Curso Planificación y Toma de Decisiones en IA, UTEC **Dataset** IEEE-CIS Fraud Detection, partición `train`, 590 540 transacciones en 182 días **Semilla** 42. **Retraso de etiqueta** $L = 30$ días. **Cadencia** 15 días

Resultado principal. El olvido por ventanas fijas no reduce el costo sobre IEEE-CIS con este protocolo. La ventana elegida en desarrollo, W60, resulta un 6,4 % más cara que el modelo estático en el periodo de test. La ventana más corta, W30, es la peor de las cinco estrategias. El informe documenta el resultado tal como se obtuvo y analiza por qué ocurre.

Página 1. El problema de decisión

Predecir no basta

El sistema decide, para cada transacción, entre aprobar, enviar a revisión o bloquear. Cuatro restricciones definen qué significa un buen modelo en este contexto.

1. La etiqueta confirmada llega 30 días después del evento. Ninguna métrica de error está disponible en el momento de decidir.
2. La capacidad humana de revisión es de 150 casos diarios. Constituye un techo, no un parámetro a optimizar.
3. Un falso negativo cuesta el monto de la transacción. Un falso positivo cuesta fricción con un cliente legítimo.
4. La distribución de los datos cambia con el tiempo.

Objetivos y verificación

Obj.	Enunciado	Criterio	Resultado obtenido
O1	Menor costo que la política actual y que el modelo estático	Inferior a 5,40 y a 1,53 UM/tx	Parcial. Supera aprobar todo. No supera al estático
O2	Limitar la caída de PR-AUC	Caída superior al 10 % genera alerta	El AP de S0 pasa de 0,526 a 0,509 entre bloques extremos
O3	Respetar la capacidad de revisión	150 casos diarios como máximo	Cumplido en 62 días sin excepción
O4	Señales sin etiqueta que anticipen la caída	Medir el retraso de cada señal	KS/PSI y S1 el mismo día. ADWIN a 30 días
O5	Limitar la disparidad entre segmentos	Brecha superior a 2 pp genera alerta	6 de 14 segmentos superan el umbral

Familias de métricas

Las métricas técnicas comprenden Average Precision, skill normalizado por prevalencia, F1 y balanced accuracy en un umbral declarado, recall a FPR máximo del 1 %, recall a precisión mínima del 80 %, Brier, ECE y latencia p50, p95 y p99.

Las métricas de decisión comprenden costo observado simulado por transacción, monto de fraude evitado, costo de falsos positivos, retorno por analista hora, revisiones diarias y demanda excedente.

Las métricas sociales comprenden el bloqueo de clientes legítimos, distinto del FPR del clasificador porque incorpora las legítimas que el analista bloquea por error, la disparidad por segmento con soporte e intervalos, y la cobertura automática.

El sistema distingue el cambio en $P(X)$ del cambio en $P(y|X)$. KS/PSI y el domain classifier detectan el primero. Solo ADWIN sobre el error real observa el segundo, con 30 días de retraso.



Figura 1. Comparación de las cinco estrategias sobre los mismos eventos. El diagrama de los cinco componentes está en `docs/arquitectura.mmd`.

Componentes

La adquisición integra dos fuentes tabulares mediante left join uno a uno por `TransactionID`, validado por invariancia del número de filas. El predictor compara regresión logística, Random Forest y LightGBM, con el preprocessing ajustado dentro de cada fit. La decisión aplica una política de costo esperado con dos umbrales y cupo. La incertidumbre se trata con calibración de Platt por versión e intervalos por bootstrap de bloques. La acción produce tres salidas simuladas con cola priorizada y apelación documentada.

Cálculo de la decisión

Para probabilidad calibrada p y monto m ,

$$\begin{aligned} E[\text{aprobar}] &= p * m \\ E[\text{bloquear}] &= (1 - p) * c_{FP} \\ E[\text{revisar}] &= c_R + p * (1 - r_H) * m + (1 - p) * f_H * c_{FP} \end{aligned}$$

con $c_{FP} = 5 \text{ UM}$, $c_R = 1 \text{ UM}$, $r_H = 0,90$ y $f_H = 0,02$. La unidad monetaria es consistente con `TransactionAmt` y no se convierte a moneda.

La revisión no siempre resulta más barata. Con montos bajos el costo fijo c_R supera la pérdida esperada y la política prefiere una acción automática. Esa es la razón de que exista una zona gris en lugar de un umbral único.

Evidencia sobre la necesidad de calibrar

La aritmética anterior exige que p sea una probabilidad. La configuración ganadora de la regresión logística usa `class_weight=balanced`, que infla los puntajes de forma severa. Los datos reales cuantifican el efecto.

Familia	Brier crudo	Brier calibrado	ECE crudo	ECE calibrado
Logística <code>lr_c1_bal</code>	0,14988	0,03170	0,29388	0,00437
Random Forest <code>rf_200_20</code>	0,05440	0,02521	0,14777	0,00433
LightGBM <code>lgbm_31</code>	0,01991	0,01978	0,00348	0,00130

El ECE de la logística mejora en un factor de 67. Sin esa corrección, usar el puntaje crudo como probabilidad produciría un exceso de bloqueos que el AP no reflejaría.

Cola y cupo

El cupo se reserva al admitir, de forma irrevocable y por `event_id`. El sistema no ordena el día completo por $p * \text{monto}$ para retener los 150 mejores casos, porque esa operación requeriría conocer transacciones que aún no ocurrieron. La prioridad ordena el servicio entre los casos ya admitidos. Agotado el cupo, el caso recibe la más barata entre aprobar y bloquear.

Supervisión humana

Ninguna alerta despliega por sí sola. El reentrenamiento y la promoción exigen autorización humana registrada aunque todos los gates técnicos pasen. Sin versión válida el servicio responde 503 y pausa, sin decidir el pago ni degradar a una referencia no desplegable.




Figura 2. Prevalencia semanal con intervalo de Wilson, volumen, faltantes por familia de columnas y cobertura de identidad.

Integración auditada

Comprobación	Resultado
Transacciones	590 540 filas, 394 columnas
Identidad	144 233 filas, 41 columnas
Filas tras el join	590 540, invariante
Cobertura de identidad	24,42 %
Identificadores de identidad huérfanos	0
Prevalencia global	3,50 %, 20 663 fraudes
Monto mediano	68,77

La ausencia de identidad constituye información y se preserva en `has_identity`. Eliminar esas filas sesgaría el panel hacia clientes con dispositivo identificado.

Relojes derivados

`TransactionDT` es un delta en segundos desde un origen desconocido, no una fecha. De él se derivan `dia`, `semana` y una `hora` relativa que funciona como ciclo de 24 horas y no identifica hora local ni día laboral.

El reloj de evento determina qué features son visibles. El reloj de disponibilidad, definido como `available_at = dia + 30`, determina cuándo una etiqueta puede entrar a un fit, a una métrica o a ADWIN.

Features causales y calidad de los proxies

El sistema construye dos proxies de entidad. El proxy de tarjeta combina `card1` a `card6` con `addr1`. El proxy de dispositivo combina `DeviceType` con `DeviceInfo`. Para cada uno calcula conteos y montos en ventanas de 1 hora, 24 horas y 7 días, rezago del monto, tiempo desde el último evento y conteo expansivo.

Proxy	Entidades	Eventos por entidad	Fracción de singletons
Tarjeta	43 018	13,7	40,4 %
Dispositivo	1 943	74,2	26,0 %

El 40 % de singletons en el proxy de tarjeta limita el soporte de las features de historial. Un proxy agrupa comportamiento y no identifica personas.


Controles de leakage

Las 137 pruebas de `tests/` verifican los controles. Cuatro resultan decisivas. Alterar las filas futuras no modifica medianas ni vocabulario del preprocessing. Invertir las etiquetas aún inmaduras no cambia el predictor. Permutar los identificadores de eventos con el mismo timestamp deja las features idénticas. Los cuatro roles de cada versión no comparten ningún `TransactionID`.

Página 4. Protocolo temporal

Particiones

Todos los intervalos son semiabiertos y se expresan en días relativos.



En cada actualización T de {120, 135, 150, 165}, con $c = T - 30$, los roles se distribuyen de la forma siguiente.

Rol	Intervalo	Días efectivos
Predictor	$[c-W, c-21)$	9 con W30, 39 con W60, 69 con W90
Calibrador	$[c-21, c-14)$	7
Reserva de política	$[c-14, c-7)$	7
Validación de promoción	$[c-7, c)$	7

Las tres reservas son idénticas para todas las estrategias. Esa igualdad permite atribuir una diferencia de costo al tamaño de ventana.

Distinción entre cutoff y tiempo del job

$cutoff = T - L$ delimita qué días de evento pueden usarse. $job_time = T$ indica cuándo se ejecuta el ajuste y constituye el valor contra el que se compara $available_at$. Con T igual a 120 y L igual a 30, el último día de evento con etiqueta confirmada es el 89. Comparar contra $cutoff$ en lugar de job_time exigiría $dia < 60$ y dejaría vacías las colas de calibración, política y validación.

Orden de construcción

El orden es predictor, calibrador, política y validación. Cada paso consume scores producidos por el anterior sobre datos que ese paso no vio. Invertir el orden haría que el calibrador corrigiera un modelo distinto del que se despliega.

Si un rol no alcanza el soporte mínimo de 200 fraudes y 2 000 legítimas en el fit, la versión se marca no válida. El sistema no amplía la ventana ni incorpora etiquetas inmaduras para completar el soporte.

Prerregistro

La familia, los hiperparámetros, los umbrales y la ventana desplegable se congelan usando solo desarrollo. El hash 6029a7722645b957 sella esa selección antes de abrir el test. Si la configuración cambiara entre la selección y el test, la corrida se detiene.

El benchmark histórico que seleccionó IEEE-CIS ya examinó periodos tardíos del dataset. Este trabajo continúa siendo un backtest retrospectivo y no una validación prospectiva.




Figura 3. Evolución de AP, costo y Brier del sistema estático en el periodo de test, con la tasa base superpuesta.

Comparación de familias

La selección aplica el criterio de costo, no el de AP. El proceso ejecuta 18 fits de tuning y tres ajustes finales.

Familia	Config	AP	Costo UM/tx	Umbral
LightGBM	lgbm_31	0,6105	1,1963	0,0067 y 0,9041
Random Forest	rf_200_20	0,5404	1,4957	0,0000 y 0,2408
Logística	lr_c1_bal	0,3986	1,5325	0,0158 y 0,2058

Las referencias simuladas sobre la reserva de política alcanzan 4,5937 UM/tx al aprobar todo y 4,8273 UM/tx al bloquear todo. LightGBM queda congelado como familia adaptativa.

Los umbrales no se fijan en 0,5. Resultan de minimizar el costo observado sobre [76,83] recorriendo pares de cuantiles del score.

Selección de la ventana desplegable

El protocolo exige elegir la ventana con datos de desarrollo. La evaluación se realiza sobre la reserva de política, posterior al predictor y al calibrador de cada paquete.

Estrategia	Días de fit	Fraudes en el fit	Costo UM/tx en desarrollo
W60	39	4 868	1,1909
W90	69	8 269	1,1963
W30	9	1 291	1,4743

W60 y W90 quedan separadas por un 0,45 %, dentro del margen de desempate del 1 %, que favorece la ventana menor. W30 queda un 23,8 % por encima. El desarrollo anticipa que la ventana más corta es la peor opción.

W60 constituye la recomendación operativa y fue elegida sin observar el test.

Página 6. Resultado del experimento central

Cinco estrategias evaluadas sobre los mismos eventos, la misma semilla, la misma política y la misma familia. 175 998 eventos por estrategia en cuatro bloques.

Estrategia	AP	Skill	Brier	Costo UM/tx con IC 95 %	Acosto frente a S0 con IC 95 %	Bloqueo legítimas	Versiones
E15 (ref.)	0,4870	0,4687	0,0238	1,4961 [1,402 y 1,604]	-0,032 [-0,058 y -0,009]	11,51 %	3
W90	0,4775	0,4589	0,0241	1,5230 [1,443 y 1,623]	-0,005 [-0,035 y +0,026]	11,87 %	3
S0 (ref.)	0,4799	0,4614	0,0239	1,5282 [1,440 y 1,622]	referencia	10,79 %	1
W60 (elegida)	0,4636	0,4445	0,0245	1,6262 [1,494 y 1,782]	+0,098 [+0,009 y +0,196]	12,24 %	3
W30	0,4267	0,4062	0,0252	1,7924 [1,655 y 1,925]	+0,264 [+0,174 y +0,367]	12,82 %	2

Costo de aprobar todo en test 5,3978 UM/tx. Intervalos por bootstrap pareado de bloques contiguos de 7 días con 200 remuestreos. S0 y E15 son referencias no despleables.

Interpretación

El olvido no compensa sobre IEEE-CIS. La ventana más corta resulta la más cara con un intervalo que no cruza el cero. La ventana elegida en desarrollo queda un 6,4 % por encima del modelo estático, también con intervalo que excluye el cero. Solo la referencia expansiva E15 mejora al estático, y su ventaja de 0,032 UM/tx equivale al 2,1 %.

El ordenamiento observado es inverso al que produciría un escenario de drift rápido. La explicación resulta consistente con las señales medidas. El domain classifier obtiene un AUC de 0,654, por debajo del umbral de alerta de 0,75, lo que indica que P(X) cambia poco a lo largo de los 182 días. En ese régimen el costo en varianza de entrenar con 9 días supera cualquier beneficio de frescura.

AP por bloque

Estrategia	B1	B2	B3	B4
E15	0,5255	0,3882	0,4941	0,5366
W90	0,5255	0,3882	0,4787	0,5224
S0	0,5255	0,3882	0,4727	0,5092
W60	0,5102	0,3531	0,4811	0,5173
W30	0,4771	0,3238	0,4270	0,4720

El descenso común en B2 afecta a las cinco estrategias por igual, incluidas las que se reentrenan. Corresponde a un periodo más difícil y no a un modelo que caduca. El sistema estático no muestra degradación monótona.

Objetivos diagnósticos no alcanzados

Los umbrales se eligieron en validación y se aplicaron congelados.

Estrategia	Recall a FPR 1 %	FPR real	Recall a precisión 80 %	Precisión real
S0	0,4216	1,34 %	0,3483	72,65 %
E15	0,4367	1,39 %	0,3497	72,48 %
W60	0,4278	1,42 %	0,3337	70,34 %

Ninguna estrategia alcanza el FPR máximo del 1 % ni la precisión mínima del 80 % en test. El informe reporta el nivel obtenido y no ajusta el umbral, porque hacerlo convertiría un objetivo incumplido en un resultado ajustado a posteriori.

Señales de drift

ADWIN registra 33 detecciones repartidas entre las cinco estrategias, todas con exactamente 30 días de retraso. Existe por tanto deriva en el error real. KS/PSI y S2 generan 5 alertas sobre 373 registros, concentradas a partir del día 170. El domain classifier no supera su umbral.

La combinación resulta informativa. El error deriva, las covariables se mantienen estables y reentrenar con ventanas cortas no corrige esa deriva.

Gates de promoción

En T igual a 135 las cinco estrategias fueron bloqueadas por el gate social, que detecta un aumento del bloqueo de legítimas superior a 2 puntos porcentuales. W30 falló además el gate de no inferioridad de costo en T igual a 150 y operó con un modelo antiguo durante la mayor parte del test. Los gates no son decorativos.

Página 7. Despliegue, operación y costo

Entregado frente a diseñado

Entregado y verificado localmente	Ejecuta el equipo de forma manual
Paquete versionado con hashes	Publicación de la imagen en Artifact Registry
Imagen Docker construida y probada	Creación del servicio en Cloud Run
Servicio HTTP con <code>/health</code> y <code>/predict</code>	Apuntar el replay al endpoint remoto
Replay con ledger SQLite transaccional	Promoción, rollback y cierre de recursos
Runbook y política de promoción	

Pub/Sub, Firestore, BigQuery, Cloud Scheduler y Vertex AI Pipelines figuran en el diagrama como diseño futuro. No existen recursos creados ni código de integración.

Evidencia de la demo local

Comprobación	Resultado
Tres acciones sobre datos reales	Presentes en el replay
Cupo respetado	150 de 150, nunca excedido en 62 días
Idempotencia con 50 reenvíos	Aprobada, sin consumo adicional de cupo
Imagen Docker	linux/amd64 , 1,06 GB, HEALTHCHECK en verde
Paridad contenedor frente a cálculo offline	5 de 5 idénticas con tolerancia 1e-12
Latencia p95 sobre HTTP al contenedor	87,2 ms frente a un objetivo de 300 ms
Sin paquete montado	<code>/health</code> informa <code>model_unavailable</code> y <code>/predict</code> devuelve 503
Cambio de versión y rollback	Score restaurado de forma exacta

Frecuencia, autonomía y gates

El reentrenamiento ocurre cada 15 días con la ventana W60 elegida en desarrollo. El monitoreo aplica KS/PSI a diario, S1 por bloque y ADWIN al madurar cada etiqueta. Cinco gates controlan la promoción. El primero verifica integridad y bloquea la versión ante cualquier leakage. El segundo exige costo inferior al de aprobar todo en el arranque. El tercero aplica no inferioridad con costo máximo de 1,01 veces el del champion, caída de AP no superior a 0,01 y aumento de Brier no superior a 0,005. El cuarto limita el aumento del bloqueo de legítimas a 2 puntos porcentuales. El quinto exige autorización humana registrada.

El rollback técnico responde a errores HTTP superiores al 1 % o a p95 por encima de 300 ms en dos lotes consecutivos, y opera de forma inmediata bajo regla preautorizada. El deterioro de negocio solo puede afirmarse con etiquetas maduras, 30 días después, y exige revisión humana.

Costo de cómputo

Trabajo	Tareas	Minutos
Tuning	18	17,3
Ajustes finales y de adaptación	6	9,9
Selección de ventana	3	0,8
Backtest completo	1	3,2
Datos y features	5	0,3
Total	33	31,5 de 480

El perfil reducido de recursos previsto en el plan no resultó necesario.

Escala, costo e integración

El informe no estima montos porque dependen de la cuenta, la región y el tráfico. Los factores de costo son el consumo de CPU y memoria por petición junto con el cold start en serving, el tamaño de la ventana y el ancho del panel en reentrenamiento, y el número de versiones retenidas junto con el volumen de logs en almacenamiento.

Tres límites quedan declarados. El cupo está garantizado únicamente para un orquestador secuencial. La latencia medida es local y no representa una región cloud. El prototipo asume identidad simultánea y features precomputadas.

Página 8. Límites y conclusión

Afirmaciones que no se sostienen

Afirmación	Motivo
El olvido mejora el costo	No ocurre sobre IEEE-CIS. W60 resulta un 6,4 % más cara que el estático
Existe concept drift demostrado	ADWIN detecta deriva en el error. La comparación temporal no identifica causalmente el cambio en $P(y X)$
W60 es la ventana óptima	Es la mejor de tres evaluadas en desarrollo, con una cadencia y una semilla
El sistema es justo	La disparidad medida es operativa sobre variables de negocio, sin atributos protegidos verificables
El sistema funciona en producción	El cupo está garantizado solo para un orquestador secuencial
Existe un ahorro económico medido	Los costos son simulados bajo supuestos declarados

Por qué el olvido no compensa en este dataset

Las señales medidas ofrecen una explicación coherente. El domain classifier alcanza un AUC de 0,654, por debajo del umbral de 0,75, lo que indica estabilidad de $P(X)$ durante los 182 días. Las alertas de KS/PSI aparecen solo a partir del día 170. En ese régimen la ventana corta pierde información sin ganar frescura útil.

El soporte refuerza la explicación. W30 entrena con 1 291 fraudes frente a los 8 269 de W90. El proxy de tarjeta presenta un 40 % de singletons, de modo que las features de historial aportan menos de lo que aportarían con entidades recurrentes.

El resultado no invalida el diseño adaptativo. Indica que la cadencia de 15 días con L igual a 30 no encuentra, en este dataset, una deriva suficiente para justificar el descarte de datos.

Selective labels y restricción dominante

El núcleo emplea información completa, de modo que toda etiqueta madura a los 30 días incluso si la acción simulada fue bloquear. En operación real una transacción bloqueada no revela su desenlace y las etiquetas disponibles quedarían sesgadas por las decisiones previas del sistema. La corrección mediante masked label quedó fuera del alcance.

La demanda de revisión supera el cupo de 150 casos diarios de forma sistemática. El cuello de botella es la capacidad humana y no la calidad del modelo. Mejorar el AP presenta rendimientos decrecientes mientras la mayor parte de la zona gris reciba una acción automática por falta de capacidad.

Los riesgos residuales cuentan con controles entregados. Los scores descalibrados se corrigen con Platt por versión sobre una cola separada. La oscilación de versiones se limita con cadencia y cooldown de 15 días sin retuning por alertas. Las etiquetas tardías se gobiernan con `available_at` y predicciones inmutables. La ausencia de modelo válido produce 503 y pausa. El retuning tras observar el test queda bloqueado por el hash de preregistro.

Conclusión

El sistema reduce el costo observado de 5,40 a 1,53 UM por transacción frente a aprobar todo, lo que representa una mejora del 71,7 %. Ese resultado proviene del modelo y de la política económica, no de la adaptación.

El olvido por ventanas fijas no aporta mejora sobre IEEE-CIS con este protocolo. La ventana elegida en desarrollo resulta un 6,4 % más cara que el modelo estático en test, con un intervalo pareado que excluye el cero. La ventana más corta resulta un 17,3 % más cara. Únicamente la referencia expansiva mejora al estático, en un 2,1 %.

Ninguna estrategia alcanza los objetivos diagnósticos de FPR máximo del 1 % ni de precisión mínima del 80 % con los umbrales congelados. La capacidad de revisión resulta más limitante que la calidad del modelo.

La recomendación operativa es W60, elegida en desarrollo, acompañada de la advertencia de que no supera al modelo estático en el periodo evaluado. Un despliegue razonable mantendría el modelo estático con monitoreo activo y reevaluaría la ventana cuando las señales de covariables indiquen una deriva mayor que la observada.

Este trabajo constituye un backtest retrospectivo. Un backtest no demuestra que el sistema funcione en el futuro.

Trazabilidad

Cada cifra es trazable a un `run_id` y a un artefacto con hash en `reports/indice_evidencia.csv`.

Los antecedentes son `propuesta_proyecto1_final.md`, `concept_drift_findings.md` y `concept_drift_benchmark_instructions.md`. El benchmark que seleccionó IEEE-CIS se cita como evidencia consistente con drift, no como prueba causal, y sus limitaciones de preprocessing quedan declaradas.

El protocolo está en `docs/protocolo_experimental.md`, el contrato en `docs/contrato_sistema.md` y la reproducción en `docs/reproducibilidad.md`. El despliegue está en `deploy/gcp_runbook.md` y `deploy/promocion_rollback.md`. La evidencia ejecutable consta de tres notebooks en `notebooks/` y 137 pruebas en `tests/`.