

Sistema adaptativo de decisión ante fraude transaccional

Curso: Planificación y Toma de Decisiones en IA, UTEC.
Dataset: IEEE-CIS Fraud Detection, partición `train`, 590 540 transacciones en 182 días.
Parámetros: semilla 42, retraso de etiqueta $L = 30$ días, reentrenamiento cada 15 días.

Resumen. El sistema decide para cada transacción entre aprobar, enviar a revisión o bloquear, con una política de costo esperado sujeta a un cupo de 150 revisiones diarias. Frente a aprobar todo, reduce el costo de 5,40 a 1,98 UM por transacción. Sobre IEEE-CIS la distribución de entrada se mantiene estable (AUC de 0,551 en el `domain classifier`), mientras que la relación entre features y fraude cambia con el tiempo: con el volumen de entrenamiento fijo en 46 días, retrasar 16 días el corte de los datos encarece 0,106 UM/tx, y es la única comparación que resiste 18 combinaciones de semilla y bloque. La estrategia más barata es el reentrenamiento periódico sobre todo el histórico (E15); las tres ventanas deslizantes cuestan más que E15 y ninguna supera de forma estable al modelo estático.

1. Problema, objetivos, restricciones y métricas

Caso de uso

Un comercio electrónico procesa del orden de 3 200 transacciones diarias con tarjeta. Un fraude no detectado cuesta el monto de la transacción; bloquear a un cliente legítimo genera fricción y costo de atención. El problema se formula como clasificación binaria sobre `isFraud`, cuya probabilidad alimenta una decisión de tres acciones, y el desempeño se vigila en el tiempo para decidir cuándo readaptar el modelo.

Objetivos y resultado obtenido

Obj.	Enunciado	Criterio	Resultado
O1	Menor pérdida que la política actual y que el modelo estático	Costo inferior a 5,40 (aprobar todo) y a 2,09 UM/tx (S0)	1,98 UM/tx con E15. Frente a S0 la ventaja es de 5,2 % y su intervalo incluye el cero
O2	Sostener la detección en el tiempo	Una caída de AP superior al 10 % genera alerta	El AP de S0 pasa de 0,526 en B1 a 0,514 en B4. La baja de B2 afecta por igual a todas las estrategias
O3	Operar dentro de la capacidad de revisión	Como máximo 150 casos diarios	Se cumple los 62 días del test
O4	Señales sin etiqueta que anticipen la degradación	Retraso de cada señal frente al error confirmado	KS/PSI y <code>domain classifier</code> no registran cambio en $P(X)$. ADWIN confirma deriva del error 30 días después del evento
O5	No concentrar el error en un segmento	Una brecha superior a 2 pp en bloqueo de legítimas genera alerta	En validación la brecha máxima es 0,70 pp. En test, con W60, 2 de 14 segmentos con soporte superan el umbral (DeviceType desktop y mobile, 2,1 y 2,2 pp)

Restricciones

De datos: solo la partición `train` tiene etiqueta, las features `V*`, `C*` y `D*` están anonimizadas, el periodo cubre 182 días y hay columnas con más de 90 % de faltantes. Operativas: la decisión se emite durante la autorización; la etiqueta confirmada llega 30 días después del evento, supuesto de simulación dentro del plazo de disputa de las redes de tarjetas; el cupo de 150 revisiones es un límite duro; y una transacción bloqueada no revela su desenlace (selective labels). De recursos: 480 minutos de cómputo acumulado y 4 hilos.

El sistema tiene vedadas cinco decisiones: cerrar o suspender cuentas, reportar a centrales de riesgo, bloquear sin canal de apelación, reentrenarse o promover una versión sin autorización humana, y dar explicaciones causales al cliente a partir de variables anónimas.

Métricas

Técnicas: Average Precision (AP) y su skill sobre la prevalencia, F1 y balanced accuracy en el umbral de FPR 1 % fijado en validación, recall a FPR máximo de 1 %, recall a precisión mínima de 80 %, Brier, ECE y latencia p50, p95 y p99. Se prioriza AP porque con 3,5 % de positivos el ROC-AUC queda dominado por la clase negativa.

De decisión: costo observado simulado por transacción, monto de fraude evitado, revisiones diarias y demanda que excede el cupo.

Sociales: tasa de bloqueo de clientes legítimos, que incluye los bloqueos erróneos del analista, disparidad de esa tasa por segmento con intervalo y soporte mínimo, y cobertura automática.

2. Diseño del sistema




Figura 1. Componentes e interacciones. La fila superior es el flujo de cada transacción; la inferior, el ciclo de retroalimentación. Fuente: docs/arquitectura.dot.

Componentes

La adquisición integra transacciones e identidad con un left join uno a uno sobre TransactionID, validado por la invariancia del número de filas. Ambas fuentes son tabulares, de modo que el sistema implementa integración de varias fuentes; texto de producto y señales de sesión figuran en el diagrama como extensión. El módulo predictivo compara regresión logística, Random Forest y LightGBM con el preprocesamiento ajustado dentro de cada fit. La incertidumbre se trata con una calibración de Platt propia de cada versión y con intervalos por bootstrap de bloques de 7 días. La decisión elige la acción de menor costo esperado y la acción se ejecuta mediante un servicio HTTP y un replay que reserva el cupo.

Decisión por costo esperado

Para una probabilidad calibrada p y un monto m :

```

E[aprobar] = p * m
E[bloquear] = (1 - p) * c_FP
E[revisar] = c_R + p * (1 - r_H) * m + (1 - p) * f_H * c_FP

```

con $c_R = 1$ UM, $r_H = 0,90$ y $f_H = 0,02$. La unidad es la de TransactionAmt. La transacción va a revisión cuando $\min(E[aprobar], E[bloquear]) - E[revisar] > \lambda$; en otro caso recibe la más barata entre aprobar y bloquear. El punto de indiferencia entre aprobar y bloquear es $p^* = c_{FP} / (m + c_{FP})$, que depende del monto. Sobre la reserva de desarrollo, la mejor regla de dos umbrales fijos sobre p cuesta 1,9696 UM/tx y la regla económica 1,5895, aun eligiendo los umbrales sobre esa misma reserva.

Los dos parámetros se derivan de cantidades observables. El costo de un falso positivo c_{FP} se fija como el menor valor que mantiene el bloqueo de legítimas bajo el 1 % declarado: resulta 25 UM, con 0,89 %. λ es el precio sombra del cupo, el menor valor que ajusta la demanda diaria a 150 plazas, y resulta 7,86 UM. Ninguna de las dos calibraciones usa el costo observado, se ajustan alternando hasta estabilizarse en tres pasadas y quedan selladas en el preregistro.

Calibración, cola y supervisión

La aritmética anterior exige que p sea una probabilidad. La regresión logística con `class_weight=balanced` alcanza un ECE de 0,285; Platt lo reduce a 0,0044.

El cupo se reserva al admitir cada caso, de forma irrevocable y por `event_id`, sin ordenar el día completo por $p \times \text{monto}$, porque eso exigiría conocer transacciones futuras. Agotado el cupo, el caso recibe la acción automática más barata. Una alerta de drift genera una recomendación; el reentrenamiento y la promoción requieren autorización humana registrada aunque todos los gates técnicos pasen. Sin una versión válida el servicio responde 503 y la operación se pausa.

3. Datos: integración, exploración y atributos temporales




Figura 2. Prevalencia semanal con intervalo de Wilson, volumen, faltantes por familia de columnas y cobertura de identidad.

Comprobación	Resultado
Transacciones	590 540 filas, 394 columnas
Identidad	144 233 filas, 41 columnas
Filas tras el join	590 540, invariante; 0 identificadores huérfanos
Cobertura de identidad	24,4 %, preservada como <code>has_identity</code>
Prevalencia	3,50 % global (20 663 fraudes), entre 2,1 % y 5,1 % por semana
Días sin datos o de volumen anómalo	ninguno en 182 días

Relojes y cambios en la distribución

`TransactionDT` es un desfase en segundos desde un origen desconocido. De él se derivan `dia`, `semana` y una `hora` relativa, usada solo como ciclo de 24 horas. El reloj de evento determina qué features son visibles; el de disponibilidad, `available_at = dia + 30`, determina cuándo una etiqueta puede entrar a un ajuste, a una métrica o a ADWIN.

La prevalencia semanal varía entre 2,1 % y 5,1 %, mientras la distribución de las covariables permanece estable. Un domain classifier que distingue los primeros 60 días de la última semana antes de cada actualización obtiene un AUC de 0,551, con umbral de alerta en 0,75. La validación adversarial columna a columna coincide: de las 425 columnas del panel, la mediana es 0,505 y la columna original más alta, `C9`, llega a 0,600.

El avance había reportado un AUC de 0,78 a 0,95 en el benchmark que seleccionó el dataset. Las dos cifras miden cosas distintas. El benchmark comparaba la primera quinta parte del periodo con cada una de las siguientes usando todas las columnas, entre ellas `D1 – D15` sin normalizar, que miden días transcurridos y pueden separar periodos sin que cambie el comportamiento; la propuesta ya lo señalaba como riesgo. El monitor usa un panel acotado, ajusta el preprocesamiento solo en su tramo de entrenamiento y excluye las variables que crecen con el calendario.

Features causales

Se construyen tres proxies de entidad y, para cada uno, conteos y montos en ventanas de 1 hora, 24 horas y 7 días, el rezago del monto y el tiempo desde el evento previo.

Proxy	Definición	Entidades	Eventos por entidad	Singletons
Emisor	<code>card1</code> a <code>card6</code> más <code>addr1</code>	43 018	13,7	40,4 %
Cliente	<code>card1</code> + <code>addr1</code> + <code>D1n</code>	217 850	2,7	57,5 %
Dispositivo	<code>DeviceType</code> + <code>DeviceInfo</code>	1 943	74,2	26,0 %


`D1n`, el día absoluto menos `D1`, aproxima la fecha de alta de la tarjeta y separa tarjetas del mismo emisor. Con LightGBM entrenado solo sobre features de historial, la clave de emisor alcanza AP de 0,1668, la de cliente 0,1671 y ambas juntas 0,1829. Los conteos expansivos acumulan desde el primer evento y crecen con el calendario: la media de `card_cnt_expansivo` pasa de 138,8 en `[0,60]` a 707,4 en `[150,182]`. Son las dos únicas columnas del panel con AUC adversarial superior a 0,70 y quedan fuera del predictor; con ellas dentro, el domain classifier subía a 0,654.

Controles de fuga

El repositorio incluye 150 pruebas automáticas. Alterar filas futuras no modifica las medianas ni el vocabulario del preprocesamiento; invertir las etiquetas aún inmaduras no cambia el predictor; permutar eventos con el mismo timestamp deja las features idénticas; y los roles de cada versión no comparten ningún `TransactionID`.

4. Protocolo temporal

Todos los intervalos son semiabiertos y se expresan en días relativos.



En desarrollo hay tres reservas de 7 días: calibración, política y validación. La política, los umbrales diagnósticos, la familia y la ventana se eligen una sola vez sobre ellas y quedan congelados. En cada actualización T de {120, 135, 150, 165}, con corte $c = T - 30$, cada versión usa tres roles y dos reservas:

Rol	Intervalo	Días
Predictor	$[c-W, c-14)$	16 con W30, 46 con W60, 76 con W90
Calibrador	$[c-14, c-7)$	7
Validación de promoción	$[c-7, c)$	7

Como la política ya está congelada, reservarle otra ventana en cada actualización restaba siete días al predictor sin cumplir función; liberarla lleva a W30 de 9 a 16 días de fit. Las reservas son idénticas para todas las estrategias, lo que permite atribuir una diferencia de costo a la ventana.

Volumen y frescura

Variar solo el ancho W cambia a la vez cuántos días entrena el modelo y cuán reciente es su información. El diseño añade por eso un bloque que mantiene el volumen y mueve el corte.

Bloque	Estrategias	Qué varía	Qué se mantiene
Volumen variable	W30, W60, W90	días de fit	corte en $c-14$
Antigüedad variable	W60, R46_medio, R46_antiguo	punto de corte	46 días de fit
Referencias	S0 estático, E15 expansivo	reentrenamiento y olvido	misma política

R46_medio usa 46 días que terminan 30 días antes del corte c , es decir 16 días antes que los de W60, cuyo fit ya termina en $c-14$. R46_antiguo se entrena una vez sobre los días 0 a 46 y se usa hasta el día 182.

Madurez de las etiquetas y orden de construcción

$cutoff = T - L$ delimita qué días de evento pueden usarse y $job_time = T$ es el instante contra el que se compara $available_at$. Con $T = 120$ el último día con etiqueta confirmada es el 89. El orden es predictor, calibrador y validación: cada paso consume scores del anterior sobre datos que ese paso no vio. Si un rol no alcanza 200 fraudes y 2 000 legítimas, la versión se marca no válida; el sistema no amplía la ventana ni usa etiquetas inmaduras para completar el soporte.

Prerregistro

La familia, los hiperparámetros, la economía calibrada y la ventana se congelan con datos de desarrollo, y el hash `7d4c9fac0af4d15f` sella esa selección antes de abrir el test. Si la configuración cambia entre la selección y el test, la corrida se detiene. El benchmark que seleccionó IEEE-CIS ya había examinado periodos tardíos, de modo que el trabajo es un backtest retrospectivo.

5. Modelado y evaluación temporal

Sistema estatico S0 en el periodo de test




Figura 3. AP, costo y Brier del modelo estático por semana de test, con la tasa base.

Elección de modelos

La regresión logística es la referencia lineal y calibrable. Random Forest captura interacciones mediante bagging y tolera faltantes imputados. LightGBM, el enfoque avanzado, maneja de forma nativa cientos de columnas dispersas y con faltantes, que es la estructura de IEEE-CIS. Cada familia se ajusta con tres configuraciones en dos folds temporales (18 fits de tuning y tres ajustes finales) y se elige por costo.

Familia	Config	AP	Costo con regla económica	Costo con el mejor umbral fijo	ECE sin calibrar / calibrado
LightGBM	lgbm_31	0,6214	1,5895	1,9696	0,0037 / 0,0015
Random Forest	rf_200_20	0,5391	1,8728	2,2746	0,1425 / 0,0051
Logística	lr_c1_bal	0,4029	2,1910	2,8712	0,2850 / 0,0044

Sobre la misma reserva, aprobar todo cuesta 4,5937 UM/tx y bloquear todo 24,1365. LightGBM queda congelada como familia adaptativa. La regla económica induce umbrales distintos por monto:

Monto	Revisar desde	Bloquear desde
25 UM	$p \geq 0,4072$	$p \geq 0,5791$
59 UM	$p \geq 0,1747$	$p \geq 0,5143$
250 UM	$p \geq 0,0415$	$p \geq 0,3159$

Comportamiento en el tiempo

El AP del modelo estático pasa de 0,5257 en B1 a 0,5144 en B4 sin una tendencia monótona. El descenso de B2, hasta 0,3907, aparece en las siete estrategias, incluidas las que se reentrenan, y corresponde a un periodo más difícil para cualquier modelo.

Los umbrales diagnósticos se fijaron en validación y se aplican sin reajuste. En test, S0 y R46_antiguo, que no se reentrenan, cumplen ambos objetivos: FPR de 0,93 % y 0,78 %, precisión de 80,1 % y 82,5 %. Las cinco estrategias que se reentrenan aplican ese mismo umbral a versiones nuevas, exceden levemente el FPR (entre 1,06 % y 1,18 %) y su precisión queda entre 75,4 % y 78,1 %. En el umbral de FPR 1 %, el F1 va de 0,461 a 0,488 y la balanced accuracy de 0,685 a 0,706.

Selección de la ventana en desarrollo

Estrategia	Días de fit	Fraudes en el fit	Costo UM/tx en validación
W60	46	5 768	2,2527
W90	76	9 169	2,2708
W30	16	2 191	2,3501

W60 y W90 difieren en 0,80 %, dentro del margen de desempate de 1 % que favorece la ventana menor, y W30 queda 4,33 % por encima. W60 es la ventana deslizante elegida sin observar el test. El enunciado incluye el reentrenamiento periódico entre las estrategias de adaptación; en test, E15 alcanza 1,9840 UM/tx frente a 2,0921 del estático y 2,1087 de W60, y es la estrategia que el informe recomienda operar, con la salvedad de robustez de la sección 6.

6. Detección del drift y adaptación




Figura 4. Siete estrategias sobre los mismos eventos: AP y costo por semana, demanda de revisión frente al cupo y alertas por señal.

Estrategia	Días de fit	AP	F1	Costo UM/tx [IC 95 %]	Δ frente a S0 [IC 95 %]	Bloqueo legítimas
E15 (recomendada)	76 a 121	0,4965	0,488	1,984 [1,821; 2,155]	−0,108 [−0,205; 0,002]	1,26 %
W90	76	0,4901	0,481	2,057 [1,909; 2,208]	−0,035 [−0,128; 0,061]	1,36 %
S0 (estático)	69	0,4828	0,480	2,092 [1,911; 2,256]	referencia	0,87 %
W60	46	0,4802	0,480	2,109 [1,917; 2,330]	0,017 [−0,114; 0,165]	1,38 %
R46_antiguo	46	0,4681	0,472	2,117 [1,943; 2,246]	0,025 [−0,059; 0,090]	0,98 %
W30	16	0,4701	0,471	2,183 [1,943; 2,421]	0,091 [−0,061; 0,280]	1,27 %
R46_medio	46	0,4571	0,461	2,215 [2,033; 2,382]	0,123 [0,004; 0,229]	1,40 %

175 998 eventos por estrategia. Intervalos por bootstrap pareado de bloques de 7 días con 200 remuestreos.

Robustez y separación de volumen y frescura

Un intervalo obtenido con una sola semilla puede excluir el cero por azar. Cada diferencia se recalcula con 6 semillas y 3 tamaños de bloque, y solo se declara concluyente si ninguna de las 18 combinaciones cruza el cero. Las seis diferencias frente a S0 cruzan el cero en al menos una combinación; la de E15 lo hace en 8 de 18. Frente a E15, en cambio, W30, W60 y W90 son más caras con intervalos que excluyen el cero en la corrida base.

Comparación	Factor aislado	Efecto UM/tx	Combinaciones que cruzan cero	Veredicto
R46_antiguo frente a W60	frescura, corte al inicio del histórico	0,0084	18 de 18	no concluyente
W60 frente a W90	volumen y antigüedad, 46 frente a 76 días	0,0514	18 de 18	no concluyente
W30 frente a W60	volumen y antigüedad, 16 frente a 46 días	0,0742	4 de 18	no concluyente
R46_medio frente a W60	frescura, corte 16 días más antiguo	0,1059	0 de 18	concluyente
W30 frente a W90	volumen y antigüedad, 16 frente a 76 días	0,1257	1 de 18	no concluyente

Qué muestra la evidencia sobre el drift

El cambio está en P(y|X) y la distribución de entrada permanece estable. Con el volumen fijo, retrasar el corte 16 días encarece 0,1059 UM/tx en las 18 combinaciones, y como las covariables no se desplazan, ese efecto solo puede venir de la relación entre features y fraude. ADWIN, que observa el error individual con las etiquetas maduras, registra 49 detecciones entre las siete estrategias. Esas detecciones se agrupan en los mismos tramos de días de evento (128 a 132, 140, 160 a 167 y 171 a 175) tanto en las versiones recién reentrenadas como en el modelo estático, lo que indica periodos difíciles comunes a todos los modelos más que un modelo que caduca. El efecto de antigüedad no es monótono: el modelo entrenado sobre los días 0 a 46 conserva su AP (0,5077 en B1 y 0,5103 en B4) y cuesta casi lo mismo que la ventana más fresca.

Por eso 0,106 UM/tx describe ese contraste de 16 días y no una tasa por día de antigüedad. Perder volumen apunta en la misma dirección (0,126 UM/tx entre 16 y 76 días), pero con ventanas que terminan en el mismo corte más volumen implica datos más antiguos, y esa comparación no resiste el control de robustez. La evidencia directa para reentrenar con todo el histórico es que las tres ventanas cuestan más que E15.

El benchmark del avance estimaba una degradación de 19 % comparando un modelo antiguo con otro entrenado en la misma ventana que se evalúa, sin retraso de etiqueta. Con L = 30 esa referencia no es alcanzable: toda versión nace con al menos 44 días de antigüedad. Topal et al. [1], sobre el mismo dataset, observan con reentrenamiento diario que las caídas se concentran en los boosters (−89 % y −92 % de recall a FPR 5 %) y son de −24 % en Random Forest y −3 % en la logística. Aquí, LightGBM congelado 136 días (R46_antiguo) obtiene 0,377 de recall a FPR 1 % frente a 0,424 del reentrenado (E15), 11 % menos.

7. Despliegue y operación

Arquitectura de implementación

Entregado y verificado localmente	Paso manual del equipo en GCP
Paquete versionado: predictor, preprocesador, Platt, política y manifest	Publicar la imagen en Artifact Registry
Imagen Docker linux/amd64 de 1,06 GB con HEALTHCHECK	Crear el servicio en Cloud Run
Servicio HTTP con /health y /predict	Apuntar el replay al endpoint remoto
Replay con ledger SQLite transaccional, único dueño del cupo	Promoción, rollback y cierre de recursos

Pub/Sub, Firestore, BigQuery, Cloud Scheduler y Vertex AI Pipelines aparecen en `deploy/arquitectura_gcp.mmd` como diseño futuro, sin recursos creados.

Flujo de datos y evidencia de la demo

La transacción llega al servicio con sus features precomputadas; el servicio devuelve `p`, los tres costos esperados y la acción propuesta, y el replay confirma la decisión y reserva el cupo de forma atómica por `event_id`. Las etiquetas entran al monitor al madurar.

Comprobación	Resultado
Acciones sobre datos reales	4 678 aprobar, 201 revisar, 121 bloquear
Cupo e idempotencia	nunca excedido en 62 días; 50 reenvíos sin consumo adicional
Paridad entre contenedor y cálculo offline	probabilidad, costos y acción idénticos
Latencia sobre HTTP, 1 000 peticiones	p50 54,5 ms, p95 90,1 ms, p99 99,1 ms, objetivo p95 300 ms
Sin paquete montado	/health informa <code>model_unavailable</code> y /predict responde 503
Cambio de versión y rollback	el score se restaura de forma exacta

Frecuencia de actualización

La cadencia de 15 días se midió sobre los mismos bloques de test con la política congelada.

Cadencia	Fits en el test	Costo UM/tx	Beneficio captado
Sin reentrenar	1	2,0921	referencia
Cada 15 días	4	1,9840	100 %
Cada 30 días	2	2,0613	29 %
Cada 45 días	2	2,0517	37 %

Las dos actualizaciones adicionales cuestan 3,3 minutos de cómputo. El EDA no permite deducir la cadencia, porque observa `X` y la tasa base, ambas estables; con ese criterio se concluiría que no hace falta reentrenar, decisión que cuesta 5,4 % más. Cadencias menores de 15 días quedan sin evaluar.

Autonomía, monitoreo y gates

KS/PSI se aplica a diario con corrección de Benjamini-Hochberg, el domain classifier una vez por bloque y ADWIN al madurar cada etiqueta. En la corrida hubo 2 alertas sobre 497 registros de señal, ambas de PSI de scores el día 170. Cinco gates controlan la promoción: integridad frente a fugas, costo inferior al de aprobar todo, no inferioridad (costo como máximo 1,01 veces el del modelo vigente, caída de AP de hasta 0,01 y aumento de Brier de hasta 0,005), aumento del bloqueo de legítimas de hasta 2 pp, y autorización humana registrada. Las 22 evaluaciones de la corrida recomendaron promover. El rollback técnico se dispara con más de 1 % de errores HTTP o p95 sobre 300 ms en dos lotes consecutivos; el deterioro de negocio solo se afirma con etiquetas maduras y requiere revisión humana.

Escalabilidad, costos e integración

La corrida completa consume 39,5 de los 480 minutos, en 34 tareas: el tuning 19,0 y los ajustes finales y de adaptación 15,1. En operación el costo depende de CPU y memoria por petición y del cold start en serving, del tamaño de la ventana en reentrenamiento y del número de versiones y logs retenidos. El cupo está garantizado para un orquestador secuencial; con varias réplicas haría falta un ledger distribuido. La latencia se midió en local y el prototipo asume que la identidad llega junto con la transacción.

8. Riesgos, alcance y conclusión

Alcance de las conclusiones

Afirmación	Evidencia disponible
El olvido mejora el costo	Ninguna ventana deslizante supera al estático de forma estable
Existe concept drift	ADWIN detecta deriva del error y el efecto de frescura es robusto; la comparación temporal no identifica la causa
La ventana elegida es óptima	Es la mejor de tres, con una cadencia y una semilla de ajuste
El sistema es justo	La disparidad se mide por segmentos operativos; el dataset no tiene atributos protegidos
Hay un ahorro económico real	Los costos son simulados y <code>c_FP</code> es el precio sombra de un objetivo declarado

Riesgos de un sistema dinámico

Confianza. El núcleo usa información completa: toda etiqueta madura a los 30 días aunque la acción haya sido bloquear. En operación, una transacción bloqueada no revela su desenlace, y reentrenar con esas etiquetas sesgaría el modelo hacia sus propias decisiones. La corrección por etiquetas enmascaradas queda como trabajo futuro, y el analista simulado no se usa para entrenar.

Estabilidad. Una versión nueva puede cambiar la distribución de scores y con ella el nivel real de los umbrales, como ocurre con el FPR de las estrategias reentrenadas. Platt por versión, el cooldown de 15 días y los gates de no inferioridad limitan esa oscilación, y el hash de preregistro impide reajustar tras ver el test.

Decisión automatizada. El sistema resuelve de forma automática cerca del 95 % de las transacciones. Por eso las acciones de mayor impacto conservan apelación humana, la promoción de versiones requiere aprobación registrada, y sin versión válida el servicio se detiene en lugar de decidir por defecto. Los proxies de entidad agrupan comportamiento y pueden colisionar, de modo que el sistema no atribuye decisiones a personas identificadas.

Conclusión

El sistema reduce el costo simulado de 5,40 a 1,98 UM por transacción frente a aprobar todo, una mejora de 63,2 % que proviene del modelo calibrado y de la política económica. El concept drift de IEEE-CIS es real pero pequeño: el efecto de frescura es de 0,106 UM/tx al retrasar 16 días el corte, y el rango completo de las siete estrategias va de 1,98 a 2,21 UM/tx. Con un retraso de etiqueta de 30 días, la adaptación que mejor responde a ese drift es reentrenar cada 15 días sobre todo el histórico, con monitoreo continuo y promoción aprobada por una persona. Evaluar retrasos y cadencias menores que 30 y 15 días es el paso siguiente, porque es el régimen donde las ventanas deslizantes podrían aportar. Los resultados provienen de un backtest retrospectivo.

Referencias y trazabilidad

[1] Topal, Bozanta, Erer y Başar, «Handling Concept Drift in Fraud Detection: A Replication Study», 38th Canadian Conference on Artificial Intelligence, 2025.

Cada cifra se asocia a un artefacto con hash en `reports/indice_evidencia.csv`. El protocolo está en `docs/protocolo_experimental.md`, el contrato en `docs/contrato_sistema.md`, la reproducción en `docs/reproducibilidad.md` y el despliegue en `deploy/`. La propuesta del avance y el benchmark de selección están en `docs/antecedentes/`.